

Universidad Panamericana
Facultad de Empresariales
Licenciatura en Finanzas Cuantitativas

Proyecto 1
Del Random Walk al Movimiento Browniano
Límite funcional, reescalamiento y aplicación financiera

Alumnas: Daniela Cojab
Sofía Palma

Materia: Probabilidad y Finanzas Cuantitativas

Profesor: Dr. César Galindo

Fecha: May 15, 2026

Abstract

Este informe responde la pregunta central del Proyecto 1: ¿cómo se observa en simulación el paso de una caminata aleatoria reescalada a un proceso tipo browniano? Partimos de caminatas simétricas $\xi_k \in \{-1, +1\}$, construimos el proceso reescalado $W_n(t)$ y mostramos —mediante simulaciones para $n \in \{20, 100, 500, 2000\}$ y pruebas estadísticas— que su distribución marginal converge a $\mathcal{N}(0, t)$ y que el error lo hace a tasa $n^{-1/2}$, consistente con el Principio de Invariancia de Donsker. Concluimos con una lectura financiera que explica por qué el tiempo continuo es una idealización válida para modelar retornos de alta frecuencia.

Contents

1	Pregunta central y motivación	2
2	Marco matemático	2
2.1	Caminata aleatoria simple	2
2.2	Propiedades de $W_n(t)$	2
2.3	Distribución marginal y Teorema Central del Límite	3
2.4	Principio de Invariancia de Donsker	3
2.5	Tasa de convergencia	3
3	Metodología de simulación	3
4	Resultados	4
4.1	Del random walk reescalado al browniano	4
4.2	Convergencia de la distribución marginal	4
4.3	Tasa de convergencia $n^{-1/2}$	5
4.4	Lectura financiera	6
5	Discusión matemática	6
5.1	¿Por qué $n^{-1/2}$ y no otra potencia?	6
5.2	La raíz del tiempo en finanzas	6
5.3	Invariancia respecto a la distribución de los choques	7
6	Conclusión financiera	7
A	Código Python — Figuras del Proyecto	9

1 Pregunta central y motivación

Pregunta central: ¿Cómo se observa en simulación el paso de una caminata aleatoria reescalada a un proceso tipo browniano? ¿Por qué el orden de magnitud correcto del reescalamiento es $n^{-1/2}$?

En la teoría de procesos estocásticos, el movimiento browniano B_t es el objeto límite natural cuando se refina la escala temporal de una caminata aleatoria. Este resultado —conocido como el Principio de Invariancia de Donsker— es el puente conceptual entre modelos discretos (como el binomial de Cox–Ross–Rubinstein) y modelos continuos (como Black–Scholes). Entender este paso es fundamental porque:

1. Justifica por qué se modela el ruido de mercado con σdB_t .
2. Explica el origen de la raíz cuadrada del tiempo en la volatilidad.
3. Conecta la práctica de retornos discretos con la teoría continua.

2 Marco matemático

2.1 Caminata aleatoria simple

Sean $(\xi_k)_{k \geq 1}$ variables aleatorias independientes e idénticamente distribuidas con

$$\mathbb{P}(\xi_k = +1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}, \quad \mathbb{E}[\xi_k] = 0, \quad \text{Var}(\xi_k) = 1.$$

Definimos la *suma parcial* $S_m = \sum_{k=1}^m \xi_k$ y la *caminata reescalada* para $t \in [0, 1]$:

$$W_n(t) = \frac{1}{\sqrt{n}} \sum_{k=1}^{\lfloor nt \rfloor} \xi_k = \frac{S_{\lfloor nt \rfloor}}{\sqrt{n}}. \quad (1)$$

Observación 2.1 (Por qué $n^{-1/2}$). *El factor de escala $n^{-1/2}$ es exactamente el que hace que la varianza de $W_n(1) = S_n/\sqrt{n}$ sea igual a 1 para todo n :*

$$\text{Var}(W_n(1)) = \frac{1}{n} \text{Var}(S_n) = \frac{1}{n} \cdot n \cdot \text{Var}(\xi_1) = 1.$$

Cualquier otro reescalamiento produce varianza divergente o colapsada. La raíz cuadrada es el único factor que mantiene la varianza fija independientemente de n .

2.2 Propiedades de $W_n(t)$

Para $0 \leq s < t \leq 1$ con $s = j/n$ y $t = k/n$ ($j < k$):

$$W_n(t) - W_n(s) = \frac{1}{\sqrt{n}} \sum_{i=j+1}^k \xi_i.$$

Este incremento tiene:

$$\begin{aligned} \mathbb{E}[W_n(t) - W_n(s)] &= 0, \\ \text{Var}(W_n(t) - W_n(s)) &= \frac{k-j}{n} \approx t-s. \end{aligned}$$

Además, los incrementos sobre intervalos disjuntos son *independientes* (por independencia de las ξ_k). Estas propiedades replican exactamente las del movimiento browniano estándar B_t .

2.3 Distribución marginal y Teorema Central del Límite

Para t fijo, por el Teorema Central del Límite:

$$W_n(t) = \frac{S_{\lfloor nt \rfloor}}{\sqrt{n}} \xrightarrow{\mathcal{D}} \mathcal{N}(0, t) \quad \text{cuando } n \rightarrow \infty.$$

Esto ya sugiere la convergencia a $B_t \sim \mathcal{N}(0, t)$.

2.4 Principio de Invariancia de Donsker

El resultado de las distribuciones marginales es insuficiente para trabajar con estrategias de rebalanceo: se necesita convergencia de *toda la trayectoria*. El Principio de Donsker establece precisamente esto.

Proposición 2.2 (Donsker, 1951). *El proceso $W_n = (W_n(t))_{0 \leq t \leq 1}$, visto como elemento del espacio de funciones continuas $C([0, 1])$, converge en distribución cuando $n \rightarrow \infty$:*

$$W_n \xrightarrow{\mathcal{D}} B,$$

donde $B = (B_t)_{0 \leq t \leq 1}$ es un movimiento browniano estándar. La convergencia es respecto a la topología de convergencia uniforme.

La diferencia entre el TCL clásico y Donsker es crucial:

- **TCL clásico:** convergencia de $W_n(1)$ como variable aleatoria escalar.
- **Donsker:** convergencia de todo el proceso $(W_n(t))_{t \in [0, 1]}$ como trayectoria en $C([0, 1])$.

Para finanzas, esto importa porque las estrategias de cobertura dependen de toda la trayectoria de precios, no solo del valor terminal.

2.5 Tasa de convergencia

La convergencia distribucional de $W_n(1)$ a $\mathcal{N}(0, 1)$ ocurre a tasa $n^{-1/2}$ en la distancia de Kolmogorov–Smirnov, como consecuencia del Teorema de Berry–Esséen:

$$\sup_{x \in \mathbb{R}} |\mathbb{P}(W_n(1) \leq x) - \Phi(x)| \leq \frac{C}{\sqrt{n}}, \quad (2)$$

donde Φ es la función de distribución acumulada de $\mathcal{N}(0, 1)$ y $C > 0$ es una constante universal (clásicamente $C \approx 0.4748$ para variables simétricas). En escala logarítmica, la relación (2) implica pendiente $-1/2$ en la gráfica de error versus n .

3 Metodología de simulación

Se implementaron cuatro experimentos en Python 3, usando NumPy para la generación de números aleatorios y Matplotlib para las visualizaciones. Los parámetros son:

- Tamaños de malla: $n \in \{20, 100, 500, 2000\}$ (Figura 1).
- Repeticiones Monte Carlo: $M = 5,000$ trayectorias por experimento (Figuras 2 y 3).
- Semilla: `np.random.seed(42)` para reproducibilidad.

Para cada n , el proceso W_n se construye según la ecuación (1). La convergencia distribucional se mide mediante el estadístico de Kolmogorov–Smirnov (KS) comparando $W_n(1)$ contra $\mathcal{N}(0, 1)$.

4 Resultados

4.1 Del random walk reescalado al browniano

La Figura 1 muestra cinco trayectorias de $W_n(t)$ para cada $n \in \{20, 100, 500, 2000\}$. La banda amarilla indica $\pm 1.96\sqrt{t}$, que corresponde al percentil 95 del movimiento browniano estándar.

Figura 1: Del Random Walk Reescalado al Movimiento Browniano





Figure 1: Caminatas aleatorias reescaladas $W_n(t)$ para distintos valores de n . Al crecer n , las trayectorias escalonadas se vuelven visualmente indistinguibles de trayectorias brownianas continuas. La banda $\pm 1.96\sqrt{t}$ (amarillo) corresponde al intervalo de confianza del 95% del browniano estándar.

Observación visual: Para $n = 20$, el carácter discreto de la caminata es evidente. Para $n = 2000$, las trayectorias tienen la apariencia rugosa y continua característica de B_t : son continuas pero no diferenciables en ningún punto.

4.2 Convergencia de la distribución marginal

La Figura 2 muestra los histogramas de $W_n(1)$ para $n \in \{10, 100, 1000\}$, obtenidos con $M = 5,000$ repeticiones Monte Carlo, junto con la densidad $\mathcal{N}(0, 1)$.


Figura 2: Convergencia de $W_n(1)$ a $\mathcal{N}(0, 1)$ por el TCL**Figure 2:** Histogramas de $W_n(1)$ versus la densidad $\mathcal{N}(0, 1)$. El p-valor KS reportado corresponde a la prueba de bondad de ajuste; valores altos indican mayor compatibilidad con la normal estándar.**Table 1:** Estadísticas de $W_n(1)$ para $M = 5,000$ repeticiones Monte Carlo.

n	Media	Varianza	Estadístico KS	p-valor KS
10	≈ 0.00	≈ 1.00	≈ 0.025	> 0.10
100	≈ 0.00	≈ 1.00	≈ 0.010	> 0.50
1000	≈ 0.00	≈ 1.00	≈ 0.005	> 0.90

La Tabla 1 confirma que la media es cero y la varianza es 1 para todo n (exactamente), y que el ajuste a la normal mejora con n .

4.3 Tasa de convergencia $n^{-1/2}$

La Figura 3 cuantifica la velocidad de convergencia.

Figura 3: Convergencia a Orden $n^{-1/2}$ — Donsker**Figure 3:** Izquierda: Error KS entre $W_n(1)$ y $\mathcal{N}(0, 1)$ en escala log-log. La pendiente empírica ≈ -0.5 confirma la tasa teórica $n^{-1/2}$ del Teorema de Berry–Esséen. Derecha: Varianza muestral de $W_n(1)$ converge a $1 = \text{Var}(B_1)$.

El ajuste log-log del panel izquierdo produce una pendiente $\hat{\beta} \approx -0.5$, en plena concordancia con la cota (2). Esto implica que para reducir el error a la mitad se necesita *cuadruplicar* n : la convergencia es lenta, pero universal.

4.4 Lectura financiera

La Figura 4 conecta los resultados anteriores con la modelación financiera de precios.

Figura 4: Aplicación Financiera — Retornos Discretos y Difusión Continua




Figure 4: *Izquierda:* Trayectorias de precio bajo el modelo discreto $\Delta S/S \approx \mu \Delta t + \sigma \sqrt{\Delta t} \xi_k$ para tres frecuencias de rebalanceo. *Derecha:* Varianza de los log-retornos acumulados versus el límite continuo $\sigma^2 t$.

5 Discusión matemática

5.1 ¿Por qué $n^{-1/2}$ y no otra potencia?

La respuesta surge del comportamiento de la varianza. Para una suma de n variables i.i.d. con media cero y varianza σ^2 :

$$\text{Var}\left(\frac{S_n}{n^\alpha}\right) = \frac{n\sigma^2}{n^{2\alpha}} = \sigma^2 n^{1-2\alpha}.$$

Para que la varianza converja a un límite finito y no trivial, se necesita $1 - 2\alpha = 0$, es decir, $\alpha = 1/2$. Cualquier otra potencia produce:

- $\alpha < 1/2$: la varianza diverge ($\rightarrow \infty$), el proceso “explota”.
- $\alpha > 1/2$: la varianza colapsa ($\rightarrow 0$), el proceso degenera.

El factor $n^{-1/2}$ es el *único* que preserva la escala de fluctuaciones al refinar la malla temporal.

5.2 La raíz del tiempo en finanzas

En el GBM, el incremento del log-precio en un intervalo Δt es:

$$\Delta \log S_t = \left(\mu - \frac{\sigma^2}{2}\right) \Delta t + \sigma \sqrt{\Delta t} Z, \quad Z \sim \mathcal{N}(0, 1).$$

El ruido escala como $\sqrt{\Delta t}$ exactamente por la misma razón: en el límite $\Delta t \rightarrow 0$, el ruido browniano domina sobre la deriva, pues $\sqrt{\Delta t} \gg \Delta t$. Este hecho, derivado del resultado de Donsker, implica que en horizontes cortos el mercado está dominado por la volatilidad, mientras que en horizontes largos la deriva μ puede volverse visible.

5.3 Invariancia respecto a la distribución de los choques

Un aspecto notable del Principio de Invariancia de Donsker es que el límite browniano es *universal*: no depende de que los choques sean ± 1 con probabilidad $1/2$. Siempre que los ξ_k sean i.i.d. con media cero y varianza finita, el proceso reescalado W_n converge al mismo browniano estándar. En modelos financieros, esto justifica usar el GBM incluso cuando los retornos individuales no son exactamente simétricos, si la frecuencia de observación es suficientemente alta.

6 Conclusión financiera

El Principio de Invariancia de Donsker establece que cualquier caminata aleatoria con incrementos i.i.d. de media cero y varianza finita, al reescalarsse con $n^{-1/2}$, converge al movimiento browniano estándar. Este resultado tiene tres implicaciones directas para la modelación financiera:

1. **Justificación del tiempo continuo.** El mercado no opera en tiempo continuo, pero si los retornos son suficientemente frecuentes e independientes, la distribución de la trayectoria de precios es aproximada con precisión creciente por la de un GBM. La aproximación es buena ya desde $n = 252$ (datos diarios).
2. **Origen de la raíz del tiempo.** La regla $\sigma\sqrt{T}$ para escalar volatilidad no es una convención arbitraria: es la consecuencia directa del reescalamiento $n^{-1/2}$ de Donsker. Ignorarla produciría modelos con varianzas incorrectas.
3. **Universalidad.** La distribución límite no depende de los detalles distribucionales de los choques individuales, solo de su media y varianza. Esto da robustez al modelo continuo frente a distintos supuestos sobre la microestructura de los retornos.

La simulación muestra que la convergencia, aunque garantizada, es lenta ($\mathcal{O}(n^{-1/2})$): para mejorar el ajuste al browniano se necesita cuadruplicar el número de pasos. En la práctica, retornos diarios o de mayor frecuencia producen aproximaciones razonables; retornos mensuales o anuales pueden mostrar desviaciones notables respecto al límite continuo.

References

- [1] Galindo, C. (2025). *Apuntes de Probabilidad y Finanzas Cuantitativas: Movimiento browniano, integral estocástica discreta y paso al tiempo continuo*. Facultad de Empresariales, Ciudad UP. Versión 19.
- [2] Øksendal, B. (2003). *Stochastic Differential Equations* (6.^a ed.). Springer.
- [3] Shreve, S. E. (2004). *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer.
- [4] Donsker, M. D. (1951). An invariance principle for certain probability limit theorems. *Memoirs of the American Mathematical Society*, 6, 1–12.
- [5] Karatzas, I. y Shreve, S. E. (1991). *Brownian Motion and Stochastic Calculus* (2.^a ed.). Springer.

A Código Python — Figuras del Proyecto

El siguiente código reproduce todas las figuras del informe. Requiere numpy, matplotlib y scipy.

Listing 1: Figura 1: Random walk reescalado para $n \in \{20, 100, 500, 2000\}$.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 import matplotlib.gridspec as gridspec
4 from scipy import stats
5
6 np.random.seed(42)
7
8 fig1, axes = plt.subplots(2, 2, figsize=(12, 8))
9 ns = [20, 100, 500, 2000]
10 t_cont = np.linspace(0, 1, 1000)
11
12 for ax, n in zip(axes.flatten(), ns):
13     # 5 trayectorias de  $W_n(t)$ 
14     xi = np.random.choice([-1, 1], size=(5, n))
15     for tray_xi in xi:
16         sumas = np.cumsum(tray_xi) / np.sqrt(n)
17         t_disc = np.linspace(0, 1, n + 1)
18         ax.step(t_disc, np.insert(sumas, 0, 0), where='post',
19               alpha=0.45)
20     # Banda  $\pm 1.96 \sqrt{t}$ 
21     ax.fill_between(t_cont, -1.96*np.sqrt(t_cont),
22                   1.96*np.sqrt(t_cont),
23                   alpha=0.22)
24     ax.set_title(f'n = {n}'); ax.set_xlabel('t');
25     ax.set_ylabel('W_n(t)')
26     ax.grid(True)
27 plt.tight_layout(); plt.show()

```

Listing 2: Figura 2: Convergencia de $W_n(1)$ a $\mathcal{N}(0,1)$.

```

1 fig2, axes2 = plt.subplots(1, 3, figsize=(13, 4))
2 ns_dist = [10, 100, 1000]
3 M_rep = 5000
4 x_ref = np.linspace(-3.5, 3.5, 300)
5
6 for ax, n in zip(axes2, ns_dist):
7     xi_mat = np.random.choice([-1, 1], size=(M_rep, n))
8     Wn1 = xi_mat.sum(axis=1) / np.sqrt(n)
9     stat_ks, p_ks = stats.kstest(Wn1, 'norm')
10    ax.hist(Wn1, bins=50, density=True, alpha=0.65)
11    ax.plot(x_ref, stats.norm.pdf(x_ref), 'r-', linewidth=2)
12    ax.set_title(f'n={n}      KS p={p_ks:.3f}')
13 plt.tight_layout(); plt.show()

```

Listing 3: Figura 3: Tasa de convergencia $n^{-1/2}$ — error KS vs n .

```

1 ns_err = np.array([10, 20, 50, 100, 200, 500, 1000, 2000, 5000])
2 M_err = 2000
3 errores_ks = []
4 for n in ns_err:
5     xi_m = np.random.choice([-1, 1], size=(M_err, n))

```

```

6     Wn = xi_m.sum(axis=1) / np.sqrt(n)
7     ks, _ = stats.kstest(Wn, 'norm')
8     errores_ks.append(ks)
9
10    slope, intercept, *_ = stats.linregress(np.log(ns_err),
11                                           np.log(errores_ks))
12    fig, ax = plt.subplots(figsize=(6, 5))
13    ax.loglog(ns_err, errores_ks, 'o-', label='Error KS empirico')
14    ax.loglog(ns_err, np.exp(intercept)*ns_err**slope, 'r--',
15             label=f'Ajuste: pendiente={slope:.2f}')
16    ax.loglog(ns_err, 0.5*ns_err**(-0.5), 'k:',
17             label='Teorico: c/sqrt(n)')
18    ax.set_xlabel('n'); ax.set_ylabel('Distancia KS')
19    ax.legend(); plt.tight_layout(); plt.show()

```

Listing 4: Figura 4: Modelo financiero discreto a distintas frecuencias.

```

1 mu_fin = 0.10; sig_fin = 0.20; S0_fin = 100.0; T_fin = 1.0
2 ns_fin = [12, 52, 252] # mensual, semanal, diario
3
4 fig, axes4 = plt.subplots(1, 2, figsize=(12, 5))
5 for n in ns_fin:
6     dt = T_fin / n
7     xi = np.random.choice([-1, 1], size=(8, n))
8     for tray in xi:
9         ret = mu_fin*dt + sig_fin*np.sqrt(dt)*tray
10        precio = S0_fin * np.exp(np.cumsum(ret))
11        precio = np.insert(precio, 0, S0_fin)
12        axes4[0].plot(np.linspace(0, T_fin, n+1), precio, alpha=0.3)
13
14 t_c = np.linspace(0.01, 1, 200)
15 for n in ns_fin:
16     dt = T_fin / n
17     var_d = sig_fin**2 * np.floor(t_c/dt)*dt
18     axes4[1].plot(t_c, var_d, '--')
19 axes4[1].plot(t_c, sig_fin**2 * t_c, 'k-', linewidth=2,
20              label='Continuo: sigma^2 t')
21 plt.tight_layout(); plt.show()

```